

手语生成技术研究

南京大学 王铃¹, 冯可²

1. 南京大学智能软件学院, 江苏省 苏州市 215000;

2. 南京大学智能软件学院, 江苏省 苏州市 215000

指导教师: 殷亚凤 职称: 助理教授

中文摘要:

本研究旨在解决连续手语生成任务中的挑战, 采用 Transformer 模型来捕捉长时间序列中的依赖关系, 并生成流畅的手语序列。与传统的孤立手语生成研究不同, 我们专注于生成自然流畅的连续手语视频, 为了提高模型生成的准确性以及稳定性, 我们还做了一些新的尝试。首先, 我们对数据集进行了修改, 通过增加骨骼点数量, 并将提取的 2D 骨骼点根据逆向运动学原理提升到 3D, 使得骨骼点序列能够表达更加丰富的语义信息。为了有效地评估生成效果, 我们设计了一种新的评价指标: 将生成的骨骼点序列输入到新的识别翻译模型中, 并通过识别结果的准确性来判断生成效果的优劣。此外, 我们对数据中的样本长度进行了规范化, 这一策略有效提高了模型在面对短时段、低频事件时的稳健性。

英文摘要:

This study aims to address the challenges of continuous sign language generation using a multi-task Transformer model. Unlike traditional isolated sign language generation, we focus on generating natural, fluent continuous sign language videos. To improve accuracy and stability, several innovations are introduced. First, we modify the dataset by increasing the number of skeletal points and enhancing the extracted 2D skeletal points to 3D using inverse kinematics, allowing the sequences to express richer semantic information. To evaluate the generation performance, we design a new metric by inputting the generated skeletal sequences into a recognition and translation model and assessing the quality based on recognition accuracy. Additionally, we standardize the sample lengths in the training set, which enhances the model's robustness when handling short time segments and low-frequency events.

关键词: 连续手语生成; Transformer 网络; 3D 骨骼信息; 语义表达; 模型评估

一、引言

1

据 2024 年世界卫生组织的统计^[1], 全球不同程度听力受损的人口超 15 亿, 全世界人口的 5% 以上, 即 4.3 亿人, 需要康复治疗, 以解决他们的残疾性听力损失 (包括 3400 万儿童)。据估计, 到 2050 年, 将有超过 7 亿人, 即十分之一人口, 发生残疾性听力损失。对于患有严重听力障碍的人来说, 手语是表达自己、融入社会和理解沟通的主要方式。因此, 让手语表达更加普遍, 让更多的内容可以被手语表达, 让听力障碍者更方便地理解, 帮助他们在各种场合中可以无障碍地进行沟通, 变得非常重要。

过去手语生成领域的研究大多集中在离散的手语符号上, 忽视了连续手语生成中涉及的语境变化和复杂的时间依赖关系。因此, 如何高效地从输入文本生成连续流畅的手语视频, 并能够处理不同时间尺度的手语序列, 成为该领域亟待解决的关键问题。

我们使用了基于 Transformer 模型的连续手语生成方法, 旨在解决这一关键问题。与传统的孤立手语生

国家级大学生创新创业训练计划支持项目 (202410284179Z)

作者简介:

1 王铃 (2004-)、女, 贵州, 软件工程 (智能化软件), 大三, 计算机视觉。

2 冯可 (2004-)、女, 江苏, 软件工程 (智能化软件), 大三, 计算机视觉。

成方法不同，本研究专注于从文本生成连续的手语序列，并通过优化模型的训练方式，提升生成的准确性和稳定性。

我们具体的做法总结如下：

- 采用 Transformer 模型的自注意力机制，以其强大的序列建模能力为基础，能够在手语生成任务中捕捉长时间依赖关系。我们使用了多层 Transformer 结构，特别是在处理连续手语序列时，通过这种结构确保了每一帧手语姿态的生成能够基于前后帧的信息进行优化。
- 使用 PHOENIX-2014T 数据集，并基于 HRNet（High-Resolution Network）网络来提取每帧手语视频中的 2D 骨骼点数据，考虑部分脸部骨骼点。接着，采用 3D 骨骼预测器对这些 2D 骨骼点进行处理，利用逆向运动学方法将其提升至 3D 空间坐标。
- 对数据集进行了时段划分，将短时段样本进行单独训练，以提高模型对不同时间尺度数据的处理能力
- 采用一种新的评价指标，通过将生成的手语骨骼点序列输入到手语识别翻译模型中，评估其在实际手语理解中的表现。

此项研究的结构安排如下：第二部分回顾了手语生成 (SLP) 领域的相关研究；第三部分简要概括了我们的数据处理过程；第四部分介绍了我们的 Transformer 模型及其创新设计；第五部分展示了我们使用的评价指标和评价过程；第六部分介绍了我们的实验设置和实验结果；第七部分总结了本研究的主要发现并讨论了未来的研究方向。

二、 相关研究工作

手语生成技术是对口语或者文本序列进行处理，按照手语语序获得手语序列进而生成手语视频的过程。其中手语视频的生成是问题的关键点，对于手语视频的生成目前主要有手语动画视频合成、手语姿态视频生成等方向。

在手语合成动画生成方面，Glaubert 等^[2]设计了一个语音手语助手交互系统，将语音或文本进行处理后再利用基于 SIGLML 的手语动画转录技术，生成手语动画描述，最后得到连贯的手语动画。Karpouzis^[3]等利用语法解析器分析书面内容，得到初步的手语动作序列之后利用标准虚拟动作字符动画技术来合成手语动画序列。Sagaw 等^[4]开发了一个基于手语识别和生成技术的手语教学系统，利用 3D 计算机图形动画技术生成同步手语动画，具备了自由改变手势方向和动画大小的功能。

在手语姿态生成方面，Cui 等^[5]将 DAE（Dropout Auto Encoder）与 LSTM 相结合，实现对手语姿态的预测和优化。Zelinka 等^[6]提出了一种包含前馈 Transformer 和循环 Transformer 的姿态序列生成框架，构建了一种在文本和生成的骨骼姿态之间的基于神经网络的翻译器。Xiao 等^[7]还提出了一种基于 VAE 的概率骨架序列生成方法，利用基于 VAE 的编码器模型，生成随机性的姿态编码序列，并保持序列顺序等模式的不变性。Saunders 等^[8]提出了一种对抗性多通道的 SLP 方法，将手语姿态的生成看作是基于 transformer 的生成器和条件鉴别器之间的极大极小博弈。

三、 数据处理

（一） 数据集

Phoenix2014T 数据集是一个用于研究和开发手语识别和生成模型的重要资源。该数据集主要包含德国手语的视频记录，覆盖了天气预报等领域的内容。数据集中提供了两种注释形式：文本（text）和词汇（gloss）。文本注释是手语视频的自然语言描述，适用于语音识别和生成任务。而词汇注释则是手语动作的词汇表示，

更贴近手语本身的表达方式，可以作为手语生成模型的输入。这些注释为开发者提供了丰富的训练数据，能够有效提升手语识别和生成模型的性能。Phoenix2014T 数据集的多样性和注释的精确性，使其成为手语处理领域的重要基准。

(二) HrNet 网络提取 2D 骨骼

High-Resolution Network（高分辨率网络，简称 **HrNet**）是一种先进的深度学习模型，特别适用于提取 2D 骨骼点等高精度关键点检测任务。其核心思想是通过维持高分辨率特征图的表示，增强模型对细节的捕捉能力。

本研究采用 HrNet 网络对 Phoenix2014T 数据集进行 2D 骨骼点的提取，以得到数据集对应的精确骨骼点信息。

(三) 3D 骨骼预测器

初始化（initialization）：从 2D 姿态数据出发，估算 3D 姿态。包括计算根节点位置、骨骼长度和角度，最终得到初步的 3D 关节位置。

1. 反向传播优化（backpropagation-based filtering）：基于初步估计的 3D 姿态，通过梯度下降优化骨骼长度、角度等参数，使得预测的 3D 姿态与目标 3D 姿态之间的误差最小化。

优化的核心是损失函数，包括两部分：

- 1) 加权均方误差（MSE）：比较预测的 3D 位置与目标 3D 位置之间的差距，同时考虑每个骨骼点的位置置信度。
- 2) 正则化项：用于控制模型的复杂度，包括骨骼长度的和轨迹长度的正则项。

骨骼长度正则化：骨骼长度的总和，用来保持骨骼结构的一致性。

轨迹正则化：通过计算相邻时间步之间的坐标差异来平滑关节的轨迹，避免出现剧烈的跳跃或不自然的动作。

(四) 数据集划分

统计得到，Phoenix2014-T 数据集中 gloss 注释的平均长度为 7，对应手语视频的平均帧数为 115 左右，根据样本 gloss 注释的长度，将长度小于等于 5 的样本划分到短样本，短样本数据集的平均帧数为 65，将长度大于 5 的划分到长样本数据集，长样本数据集的平均帧数为 133，用来判断模型对不同长度的输入的处理能力和不同时间尺度数据的生成能力。

四、 生成模型构建

在数据准备阶段，我们已经收集了源语言和目标语言的语料库，同时对数据进行了归一化、修剪、线性插值、维度提升等预处理工作，如图 1 中的数据处理 (Data Process) 模块，同时针对源语言使用词级别构建了词汇表。

我们的生成模型基于经典的 Transformer 框架^{[9][10]}来构建的，主体由 encoder-decoder 构成，如图 1 中所示，编码器和解码器都分别由多个相同的子层构成，编码器的输出结果分别输入给解码器的所有子层中的 encoder-decoder MHA 模块，解码器的预测结果一方面可以和输入进行动态时间规整后计算 dtw 分数，作为生成效果的评估指标之一，另一方面可以使用手语翻译模型 (SLT) 重新翻译到文本和注释，并计算相似性，作为另一个评估指标。

(一) 编码器 (Encoder)

在输入 encoder 部分之前，首先需要将离散的、高维的词汇序列通过 embedding 层映射到一个连续的、低维的连续向量空间，对于每个单词，embedding 层会为其分配一个随机初始化的向量。通过训练，模型会根据任务的目标自动调整权重和偏置，进而调整这些向量，使得语义相似的单词对应的向量更为接近。在句子级别的手语生成任务中，还需要考虑每个词所在的位置对于整个句子的影响，因此还需要对每个词

的位置序号进 **encoding** 的映射，并将映射结果向量与对应的词向量进行拼接得到最终的词向量形式。然后将结果进一步输入到 **encoder** 部分。

$$\mathbf{x}'_t = \text{Concat}(\text{Embedding}(\mathbf{x}_t), \text{PositionalEncoding}(t))$$

Encoder 部分由多个相同的层组成，每层包含一个多头自注意力机制层和一个前馈网络。

1. 多头注意力机制

MHA 是 **Transformer** 模型中的核心机制之一。它通过并行计算多个自注意力机制，能够从不同的角度捕捉序列中不同部分的依赖关系。查询（**Q**）、键（**K**）和值（**V**）是注意力机制中的基本组件，由输入序列通过线性变换得到的。每个“头”（**head**）在计算时都有独立的查询、键和值映射，可以在不同的子空间中学习输入的不同表示。每个注意力头的输出被拼接成一个向量，并通过一个最终的线性层进行处理。拼接后，通过线性变换生成最终的输出，这样结合所有头的信息来形成更丰富的表示。

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \dots, \text{head}_h)W^O$$

2. 前馈网络

前馈网络提供非线性的特征变换，将经过多头自注意力（**MHA**）处理后的信息进一步转换为更丰富的表示，并且通过对每个位置独立进行处理，增加了模型的计算灵活性与并行性。在前馈网络之后使用残差连接和层归一化，残差连接将输入信息直接加到输出上，让模型的参数更新过程可以更容易地通过梯度流动，从而避免梯度消失，使得训练过程更加稳定；而层归一化通过标准化处理可以适应不同输入条件，从而让模型训练更加稳定和高效。

(二) 解码器 (Decoder)

解码器由多个相同的层堆叠而成，其中每个层主要包含三个子层：掩码多头自注意力机制、多头自注意力机制、前馈神经网络。除此之外，每个子层后都有一个残差连接和归一化操作，从而确保模型的稳定性和训练的高效性。

1. 掩码多头注意力机制：用来在生成过程中捕捉到上下文的依赖关系。使用遮掩操作，使得模型在生成下一个序列之前不能看到未来的信息，也就是说 z_{n+1} 的值只能基于 z_1 到 z_n 的值来得到。

具体来说，给定输入序列 X ，首先计算查询、键和值矩阵：

$$Q = XW^Q, K = XW^K, V = XW^V$$

其中 W^Q, W^K, W^V 是模型需要训练学习的参数矩阵。

然后，计算注意力得分：

$$\text{Attention}(Q, K, V) = \text{soft max}\left(\frac{QK^T}{\sqrt{d_k}} + M\right)V$$

其中， M 是遮掩矩阵，确保未来信息都被遮挡， d_k 是缩放因子。

最后，每个头并行计算出不同的结构，然后将结果拼接并通过线性变换：

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \dots, \text{head}_h)W^O$$

其中， W^O 是输出投影矩阵。

2. 多头注意力机制：允许解码器关注编码器输出的不同位置，从而在生成当前序列是结合编码器提供的上下文信息。其计算与自注意力机制类似。
3. 前馈全连接层网络：它对每个位置的输入独立地使用相同的两层线性变化和一个 **ReLU** 激活函数：

$$\text{FFN}(x) = \max(0, xW_1 + b_1)W_2 + b_2,$$


其中 W_1, W_2 是权重矩阵， b_1, b_2 是偏置向量。

(三) 损失函数

模型的损失函数使用的是均方误差（MSE）损失。公式如下：

$$L_{MSE} = \frac{1}{N} \sum_{i=1}^N (\hat{y}_i - y_i)^2,$$

N 是数据数量， $\hat{y}_i$ 是第 i 个数据的预测值， y_i 第 i 个数据的真实值。



(PE(Positional Encoding): 位置编码； SLT(Sign Language Translation): 手语翻译；

MHA(Multi-Head Attention): 多头注意力模型)

图 1：模型框架图

五、 评价指标

(一) 直接评价

动态时间规整 (Dynamic Time Warping, DTW) 通过非线性对齐的方式计算序列间的差异来弥补时间轴上的不对齐问题, 可以用来计算真实序列和预测序列之间的相似度。

1. 代价矩阵初始化

使用欧氏距离, 计算真实序列和预测序列的每个时间步之间的距离代价。

$$d(x_i, y_j) = \|x_i - y_j\|_2$$

2. 动态规划递推更新

根据初始化的代价矩阵, 使用动态规划算法, 分别比较纵向对齐 (从上方匹配)、横向对齐 (从左方匹配) 和时序对齐 (从左上角匹配) 的代价, 递推更新真实序列和预测序列的每个时间步之间的累计距离代价。

$$D1(i, j) = d(x_i, y_j) + \min(D1(i-1, j), D1(i, j-1), D1(i-1, j-1))$$

$D1[-1, -1]$ 即为两序列之间的最小对齐代价

3. 窗口限制和路径加权

- 1) 为防止路径的过度扭曲, DTW 算法通常引入窗口限制。窗口大小 w 控制最大可接受的匹配偏移。当 w 有限时, 代价矩阵的元素 $D(i, j)$ 只会考虑在该窗口内的匹配。若没有窗口限制 ($w=\infty$), 则允许无限制匹配。
- 2) 通过引入路径加权因子 s 来控制路径偏移的权重。较大 s 值会导致算法偏向于对角线的匹配, 从而减少路径的偏移, 使最小代价路径更加平滑。

(二) 间接评价

在评价部分, 除了直接评价我们还采用反向翻译的准确率对模型进行评价: 利用目前较为成熟的识别翻译模型, 对生成模型的生成数据进行反向翻译, 通过识别结果的准确性来判断生成效果的优劣。

对输入的骨骼点分流为身体、左手、右手、面部四个部分, 对每部分分别训练, 最后将四部分损失整合训练以训练其相关性。

六、 实验与结果

在本实验中, 我们使 PHOENIX2014T 数据集, 每个样本包含一个句子的对应视频帧序列, 从中我们提取了 53 个骨骼点的坐标作为训练数据, 其中骨骼点数量为左右手各 21 个点, 5 个脸部点和 8 个身体点。这些骨骼点序列通过预处理和编码后输入到我们的生成模型中。

在实验过程中, 我们通过训练结果进行超参数的不断调整, 最终我们的超参数设置为: 初始学习率: 0.001, 当学习率下降为 0.0002 时, 训练结束, 批次大小: 8, 最大训练周期数: 20000 轮, 我们选择了直接评价和间接评价两种方式来评估生成效果。

实验的数据结果如下表所示, 生成的手语姿态序列如图 2 所示。

实验结果

数据集 (PHOENIX2014T)	MSE LOSS	DTW	WER
注释长度不大于 5 的数据	0.0016	18.03	52.9
全体数据	0.0018	20.58	60.0




图 2：手语姿态序列示意图

七、 未来展望

本研究采用 53 个骨骼点对数据集进行训练以完成手语生成任务。在研究过程中，我们探讨了生成结果的影响因素，并提出了一些未来的改进方向：

首先，面部信息在手语中起着至关重要的作用，传递着情感和细微语义差别，这对于提高手语生成的准确性和自然度至关重要。然而，增加过多的骨骼点会使得模型复杂度过高，而面部信息对手语生成的影响相对较小。为此，未来可以考虑采用多模态信息融合的方法，将面部、手部和身体的骨骼点进行整合，通过多模态学习方法提升模型对手语细节的捕捉能力。其次，分模块训练与整体优化策略也是未来研究的重要方向。具体而言，可以将面部、手部和身体的骨骼点模型分阶段进行训练，再通过整体损失函数进行联合优化。这一策略有助于确保各部分信息之间的高度相关性和整体性，从而提升手语生成的准确性。此外，直接从文本生成手语视频也是一个有潜力的改进方向。与基于骨骼点的生成方法相比，基于视频帧的生成方法可以减少人工标注骨骼点时的误差，且让模型能够自主学习手语动作的生成规律。通过采用生成对抗网络（GANs）或变分自编码器（VAEs）等先进的生成模型，能够进一步提升生成手语视频的质量。

在数据方面，丰富数据集和应用数据增强技术是提升模型性能的关键。通过增加训练数据的多样性，特别是引入不同手语风格和不同手语者的数据，可以增强模型的泛化能力。同时，利用数据增强技术，如随机旋转、缩放、平移等手段，能够增加训练样本的多样性，有效防止过拟合现象。为了优化模型结构，在增加骨骼点和信息量的同时，应该通过模型剪枝、参数共享等技术来控制模型复杂度，从而保证训练和推理的效率。此外，尝试使用更先进的网络架构，如 Transformer 模型，能够进一步提升模型对时序信息的

捕捉能力。

最后，在评价和测试阶段，除了手语视频的质量评估外，还需要考虑手语的可读性、流畅度和自然性等多个维度的评价指标。同时，引入手语用户或专家的反馈，对生成结果进行主观评价和调整，将有助于提升模型的实用性。综上所述，未来的研究应在多个方向进行深入探索，以不断提升手语生成模型的性能和应用价值。

参考文献：

- [1] World Health Organization. Deafness and hearing loss[EB/OL]. World Health Organization, 2021-03-03. <https://www.who.int/zh/news-room/fact-sheets/detail/deafness-and-hearing-loss>.
- [2] GLAUERT J R W, ELLIOTT R, COX S J, et al. Vanessa-a system for communication between deaf and hearing people[J]. Technology and Disability, 2006, 18(4): 207-216.
- [3] SAGAWA H, TAKEUCHI M. A teaching system of japanese sign language using sign language recognition and generation[C]//Proceedings of the Tenth ACM international conference on Multimedia. ACM, 2002: 137-145.
- [4] CUI R, CAO Z, PAN W, et al. Deep gesture video generation with learning on regions of interest[J]. IEEE Transactions on Multimedia, 2019, 22(10): 2551-2563.
- [5] ZELINKA J, KANIS J. Neural sign language synthesis: words are our glosses[C]//Proceedings of the IEEE/ CVF Winter Conference on Applications of Computer Vision. IEEE, 2020: 3395-3403.
- [6] XIAO Q, QIN M, YIN Y. Skeleton-based Chinese sign language recognition and generation for bidirectional communication between deaf and hearing people[J]. Neural networks, 2020, 125: 41- 55.
- [7] SAUNDERS B, CAMGOZ N C, BOWDEN R. Adversarial training for multi-channel sign language production
- [8] Vaswani A, Shazeer N, Parmar N, et al. Attention Is All You Need[J]. Advances in Neural Information Processing Systems, 2017, 30: 5998-6008.
- [9] Saunders B, Camgoz N C, Bowden R. Progressive Transformers for End-to-End Sign Language Production[C]. Proceedings of the European Conference on Computer Vision (ECCV), 2020: 1009-1024.
- [10] Mo Guan¹, Yan Wang, Guangkun Ma, Jiarui Liu, Mingzu Sun. Multi-Stream Keypoint Attention Network for Sign Language Recognition and Translation